

pa7uiclf

Ciência da Computação

Inteligência Artificial - Conceitos e Funcionamentos

03/10/2025

Composição de Notas Bimestre

- **Trabalhos até: 2 Pontos**
- **Simulados até: 2 Pontos**
- **Prova até: 7 Pontos**

Notas:


- **APEx1 = Máximo de 1 Ponto**
- **AP01 = Máximo de 7 Pontos**

Inteligência Artificial

- **História da IA**
- **IAs, tradicionais e Generativas**
- **LLMs**
- **Tokens**
- **RAG e Embeddings**

História da IA

HISTÓRIA DA INTELIGÊNCIA ARTIFICIAL



O que é IA Generativa?

- A IA generativa representa um dos avanços mais disruptivos na área de tecnologia nas últimas décadas. Com o crescimento do volume de dados e do poder computacional, a capacidade de construir modelos que não apenas reconhecem padrões, mas criam novos conteúdos, abriu espaço para aplicações antes consideradas impossíveis.
- Enquanto a IA tradicional se concentra na análise e na previsão com base em dados conhecidos, a IA generativa inaugura um novo paradigma: o de criar a partir do aprendizado, seja para gerar texto, imagens, sons, código ou mesmo vídeos.
- **Definição e conceito fundamental:** A Inteligência Artificial Generativa (IA generativa) é um campo da IA que se concentra no desenvolvimento de modelos capazes de produzir novos dados que não existiam antes, aprendendo padrões e estruturas subjacentes a partir de dados existentes.
- **Definição e conceito fundamental:** Esses sistemas não apenas classificam ou identificam, como na IA tradicional, mas conseguem criar saídas originais que ainda mantêm coerência e contexto com os dados de treinamento.

O que é IA Generativa?

Comparação com a IA Tradicional e Estatística: A IA tradicional, especialmente aquela supervisionada, foca na classificação ou regressão com base em dados conhecidos. O modelo é treinado com exemplos rotulados (inputs e outputs conhecidos) e, depois, recebe novos dados para prever a saída mais provável.

Características principais:

- Previsão ou decisão baseada em padrões observados.
- Requer dados rotulados e consistentes.
- Tarefas típicas: detecção de fraude, classificação de e-mails (spam vs. legítimo), reconhecimento de imagem (identificar se é um gato ou cachorro), previsão de demanda.
- Limitação: não cria nada novo, apenas generaliza o que já foi aprendido.

O que é IA Generativa?

A IA generativa é treinada para entender a estrutura e os padrões internos dos dados de entrada e, a partir disso, gerar novos exemplos que seguem as mesmas regras implícitas.

Características principais:

- Produz saídas originais, como texto, imagens e sons.
- Treinada em grandes volumes de dados sem necessidade de rótulos explícitos (muitas vezes é auto-supervisionada ou não supervisionada).
- Tarefas típicas: criação de conteúdo original, síntese de dados, geração de imagens realistas, escrita automatizada, geração de código, tradução automática sofisticada.
- Capacidade de lidar com contexto longo e criar coerência (graças a arquiteturas como Transformer).

O que é IA Generativa?

Analogia prática:

IA tradicional: é como um aluno que faz provas de múltipla escolha, escolhe a melhor resposta entre opções baseadas no que já aprendeu.

IA generativa: é como um escritor que, com base na leitura de centenas de livros, escreve uma nova história original com começo, meio e fim.

O que é IA Generativa?

Como a IA Generativa Aprende?

- A IA generativa não mapeia entradas para saídas fixas, como na IA tradicional.
- Ela modela probabilidades complexas presentes nos dados.
- Funciona como um artista que aprende estilos e composições para criar algo novo e original.

O que é IA Generativa?

Como a IA Generativa Aprende?

- A IA generativa não mapeia entradas para saídas fixas, como na IA tradicional.
- Ela modela probabilidades complexas presentes nos dados.
- Funciona como um artista que aprende estilos e composições para criar algo novo e original.
- Ao ser treinada com muitos dados, a IA generativa aprende padrões e estruturas ocultas.
- Ela desenvolve uma intuição para prever quais elementos fazem sentido juntos.
- Cria um mapa probabilístico do universo do dado.
- Usa esse mapa para explorar novas combinações e gerar exemplos inéditos, mas coerentes com o que aprendeu.

O que é IA Generativa?

Abstração

- O modelo funciona como um cartógrafo do conhecimento.
- Observa montanhas, rios e cidades (os dados).
- Aprende regras para prever onde novas montanhas e rios podem surgir e como as cidades se conectam.
- Cria um novo mapa com áreas inéditas, mas coerentes e plausíveis.

Modelos autorregressivos (ex: GPT)

- Esses modelos escrevem texto palavra por palavra, usando o contexto das palavras anteriores.
- Cada palavra influencia a escolha da próxima.
- O processo continua até que o conteúdo esteja completo.
- Funciona como um escritor que mantém coerência e fluxo na narrativa.

Modelos de Linguagem (LLMs)

- **Definição:** Redes neurais massivas treinadas em vastos volumes de texto.
- **Objetivo:** Prever a próxima palavra em uma sequência, levando a textos coerentes e contextualmente relevantes.
- **Exemplos:** GPT (OpenAI), PaLM (Google), LLaMA (Meta).
- **Aplicações:** Chatbots, tradução, resumo, escrita criativa, codificação.

Modelos de Linguagem (LLMs)

Como funcionam?

1. Treinamento

- Usam bilhões (ou até trilhões) de palavras extraídas de livros, artigos, sites, etc.
- O objetivo é prever a próxima palavra em uma frase (*next word prediction*).

2. Arquitetura

- Os LLMs modernos usam **Transformers** (introduzidos em 2017), que permitem analisar contextos longos e relações entre palavras em paralelo.

3. Ajustes finos (Fine-tuning)

- Após o pré-treinamento, os modelos podem ser ajustados para tarefas específicas: responder perguntas, traduzir, gerar código, resumir textos, etc.

Modelos de Linguagem (LLMs)

Exemplos de LLMs

- **GPT (OpenAI)** → ChatGPT.
- **BERT (Google)** → ótimo para entender contexto em buscas.
- **LLaMA (Meta)** → modelos abertos de pesquisa.
- **Claude (Anthropic)** e **Gemini (Google)** → outros modelos atuais.


Limitações

- **Alucinações**: podem inventar informações.
- **Vieses**: refletem preconceitos presentes nos dados de treino.
- **Contexto limitado**: nem sempre lembram conversas longas.
- **Falta de compreensão real**: trabalham com padrões estatísticos, não com “significado” humano.

Como um LLM Gera Respostas?

1. **Entrada (Prompt):** O usuário fornece uma pergunta ou instrução.
2. **Codificação:** O prompt é convertido em uma representação numérica.
3. **Processamento:** O LLM usa seus bilhões de parâmetros para prever a sequência de palavras mais provável.
4. **Decodificação:** A sequência numérica é convertida de volta em texto legível.
5. **Geração Iterativa:** O processo se repete palavra por palavra, construindo a resposta completa.

Como um LLM gera respostas?



O que são tokens?

- **Tokens não são exatamente palavras** — são pedaços de texto.
- Dependendo do idioma e do modelo, um token pode ser:
 - uma palavra inteira ("*cachorro*"),
 - parte de uma palavra ("*cacho*" + "*rro*"),
 - ou até símbolos e espaços ("*.*" ou " ")

Exemplo:

Frase: **"IA é incrível!"**

- Pode virar tokens como: ["IA", " é", " incr", "ível", "!"]

O que são tokens?

Como os LLMs usam tokens?

1. Tokenização (entrada)

- O texto do usuário (prompt) é **quebrado em tokens**.
- Cada token vira um número inteiro, representado em uma tabela de vocabulário.

2. Embeddings

- Esses números são transformados em **vetores matemáticos** (representações que capturam significado e contexto).

3. Processamento pelo modelo

- O modelo usa **bilhões de parâmetros** para calcular, dado o contexto, **qual é o próximo token mais provável**.

4. Decodificação (saída)

- Os tokens gerados são transformados de volta em texto legível.

Bônus: O que são os parâmetros dos LLMs?



- Os **parâmetros** de um modelo de linguagem são **valores numéricos (pesos e vieses)** ajustados durante o treinamento.
- Eles definem **como os dados de entrada (tokens)** são processados e transformados em **saída (resposta)**.
- Pense neles como **botões e alavancas internos** que o modelo ajusta para “aprender” relações entre palavras, frases e contextos.

Em termos técnicos:

- Parâmetros = **pesos das conexões** entre neurônios artificiais nas camadas da rede neural.

Bônus: O que são os parâmetros dos LLMs?

Quantos parâmetros um LLM tem?

- Modelos pequenos → milhões de parâmetros.
- Modelos médios → bilhões de parâmetros.
- Modelos de ponta (como GPT-4, Gemini, LLaMA 3) → **centenas de bilhões ou até trilhões** de parâmetros.

Exemplo histórico:

- GPT-2 (2019): ~1,5 bilhão de parâmetros.
- GPT-3 (2020): ~175 bilhões de parâmetros.
- Modelos recentes → valores muito maiores (estimativas de centenas de bilhões, mas muitas vezes não são divulgados).

Bônus: O que são os parâmetros dos LLMs?

O que os parâmetros fazem na prática?

1. Codificação do significado

- Ajustam a forma como palavras/token são representados.
- Ex: reconhecer que “rei” e “rainha” têm relação próxima.

2. Atenção (Transformers)

- Parâmetros controlam a *atenção* que o modelo dá a diferentes partes do texto.
- Ex: na frase “*Maria pegou o livro porque ela gosta de ler*”, o modelo aprende que “ela” se refere a “Maria”.

3. Generalização

- Com bilhões de parâmetros, o modelo **não memoriza frases**, mas aprende padrões estatísticos da linguagem.

4. Controle da geração

- Os parâmetros ajustados permitem prever a **próxima palavra** com base em probabilidades.

Bônus: O que são os parâmetros dos LLMs?

Exemplo simplificado

Imagine um mini-modelo treinado com poucas frases:

- “O gato dorme.”
- “O cachorro corre.”

Depois do treino:

- Os parâmetros ajustados aprendem que “**gato**” e “**cachorro**” aparecem em posições semelhantes (sujeitos).
- Aprendem também que “**dorme**” e “**corre**” são ações (verbos).
- Assim, o modelo pode generalizar e criar: “**O gato corre.**”

Bônus: O que são os parâmetros dos LLMs?

Por que mais parâmetros = melhor modelo?

- **Mais parâmetros** → mais capacidade de armazenar relações complexas.
- Mas há trade-offs:
 - Requer mais **dados** para treinar.
 - Precisa de mais **cálculo e memória**.
 - Pode gerar **overfitting** (memorizar em vez de generalizar) se não houver dados suficientes.

Analogia simples

Imagine que cada parâmetro é um **botão de ajuste em um equalizador de som**:

- Com poucos botões → só dá para ajustar grave, médio e agudo.
- Com bilhões de botões → dá para afinar cada microdetalhe de cada instrumento em uma orquestra.

É isso que os LLMs fazem com a linguagem: afinam bilhões de “botões” até conseguirem gerar texto natural e coerente.

Bônus: O que são os parâmetros dos LLMs?

Resumindo:

- **Parâmetros = pesos internos que guardam o “conhecimento” aprendido.**
- São ajustados durante o treinamento para reconhecer padrões da linguagem.
- A quantidade massiva de parâmetros é o que dá poder aos LLMs modernos.

O que são tokens?

Exemplo prático

Prompt: “O céu é”

- Modelo recebe os tokens correspondentes.
- Ele calcula a probabilidade de próximos tokens, algo como:
 - " azul" → 60%
 - " lindo" → 25%
 - " grande" → 10%
 - " verde" → 5%
- Se o modelo escolher " azul", o novo texto será “O céu é azul”, e o ciclo continua até terminar a resposta.

Embeddings e Representações Vetoriais

O que são *Embeddings*?

- Um **embedding** é uma forma de representar palavras, frases, imagens ou até documentos como **vetores de números em um espaço matemático**.
- A ideia é **codificar o significado** para que o modelo consiga calcular **similaridades semânticas**.

👉 Em vez de “gato” ser apenas a palavra **"gato"**, ele vira algo como:

[0.21, -0.56, 0.88, 0.04, ...]

Embeddings e Representações Vetoriais

Como funcionam?

1. **Tokenização** → texto é dividido em tokens.
2. **Mapeamento para vetores** → cada token recebe um vetor de alta dimensão (ex: 768 ou 1536 dimensões em modelos comuns).
3. **Espaço vetorial** → palavras com significados semelhantes ficam **próximas** nesse espaço.

Exemplos de embeddings

1. Palavras semelhantes

No espaço vetorial:

- $\text{vetor}(\text{"rei"}) - \text{vetor}(\text{"homem"}) + \text{vetor}(\text{"mulher"}) \approx \text{vetor}(\text{"rainha"})$

Isso mostra que embeddings conseguem **capturar relações semânticas e analógicas**.

Embeddings e Representações Vetoriais

2. Busca semântica

Frase 1: *“Como treinar um cachorro?”*

Frase 2: *“Dicas de adestramento para cães”*


👉 Embora as palavras sejam diferentes, os **vetores ficam próximos** no espaço, permitindo busca inteligente (muito usado em **chatbots**, **pesquisa semântica e recomendação**).

Retrieval-Augmented Generation (RAG)

- Converter documentos em embeddings
- Armazenar em banco vetorial
- Buscar documentos relevantes via similaridade
- Fornecer contexto ao LLM para resposta fundamentada

Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG)



✨ Benefícios do RAG

✓ Informações Atualizadas

Base de conhecimento pode ser atualizada sem retreinar o modelo

✓ Reduz Alucinações

Respostas baseadas em documentos reais fornecidos

✓ Transparência

Pode citar e referenciar fontes específicas das respostas

✓ Controle

Total controle sobre a base de conhecimento usada

🔑 Conceitos-Chave

- 1 Embeddings**: Textos → Vetores numéricos que capturam significado
- 2 Similaridade**: Busca documentos próximos no espaço vetorial (cosine similarity)
- 3 Context Window**: Documentos relevantes são incluídos no prompt do LLM
- 4 Chunking**: Divisão de documentos longos em pedaços menores para melhor recuperação