

CENTRO UNIVERSITÁRIO MAX PLANCK
CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

**COMPRESSÃO DE PROMPTS, TOKENS E SUSTENTABILIDADE
DA IA**

Engenharia de Prompt como Estratégia de Otimização de Respostas em
Inteligências Artificiais

Trabalho de Conclusão de Curso apresentado ao
Curso de Bacharelado em Ciência da Computação
do Centro Universitário Max Planck (UniMAX),
como requisito parcial para obtenção do grau de
Bacharel em Ciência da Computação.

Orientador: Prof. Luiz Claudio Chiavini Oliveira
Junior

INDAIATUBA

2026

RESUMO

Este trabalho investiga a compressão de prompts como estratégia de otimização para Modelos de Linguagem de Grande Escala (LLMs), analisando simultaneamente o impacto computacional, o custo financeiro e a sustentabilidade ambiental decorrentes do uso intensivo dessas tecnologias. O estudo parte da Teoria da Informação de Shannon e da hipótese de redundância linguística para fundamentar técnicas modernas de compressão como LLMLingua, LLMLingua-2, LongLLMLingua, Selective Context e AutoCompressor. A pesquisa demonstra que a redução de tokens em prompts pode diminuir significativamente os custos operacionais e o consumo energético sem perda crítica de qualidade semântica. A bancada experimental avalia cenários reais de alta densidade — incluindo raciocínio em sistemas distribuídos, engenharia de dados com esquemas DDL complexos e auditoria de conformidade LGPD — confrontando abordagens Zero-shot, Few-shot e compressão algorítmica. Utilizando o BERTScore como métrica central de similaridade semântica contextual, os resultados experimentais revelam que taxas de compressão de até 4x sustentam valores de F1 consistentemente superiores a 0,86, enquanto reduzem o consumo de tokens em até 74,6% e os FLOPs do mecanismo de autoatenção em até 93,75% durante o prefill. Além do aspecto técnico e econômico com APIs de ponta, o trabalho discute os impactos ambientais no âmbito do movimento Green AI e o Paradoxo de Jevons. Conclui-se que a compressão seletiva de prompts representa uma ferramenta tecnologicamente madura, financeiramente viável e ecologicamente indispensável para a viabilização de sistemas de IA generativa em escala de produção.

Palavras-chave: Compressão de Prompts. Modelos de Linguagem de Grande Escala. Engenharia de Prompt. Green AI. BERTScore. Sistemas Distribuídos.

ABSTRACT

This work investigates prompt compression as an optimization strategy for Large Language Models (LLMs), simultaneously analyzing the computational impact, financial cost, and environmental sustainability arising from the intensive use of these technologies. The study draws on Shannon's Information Theory and the linguistic redundancy hypothesis to underpin modern compression techniques such as LLMLingua, LLMLingua-2, LongLLMLingua, Selective Context, and AutoCompressor. The research demonstrates that reducing tokens in prompts can significantly decrease operational costs and energy consumption without critical loss of semantic quality. The experimental benchmark evaluates high-density production scenarios — including distributed systems architectural reasoning, database engineering under complex DDL schemas, and LGPD data governance compliance auditing — contrasting Zero-shot, Few-shot, and algorithmic compression pipelines. Utilizing BERTScore as the primary metric for contextual semantic similarity, empirical findings indicate that compression ratios of up to 4x sustain F1-scores consistently above 0.86, while slashing input token consumption by up to 74.6% and self-attention FLOPs by up to 93.75% during the prefill phase. Beyond technical and financial analyses with state-of-the-art APIs, this work discusses environmental implications within the Green AI movement and addresses Jevons' Paradox. It concludes that selective prompt compression represents a technologically mature, financially viable, and environmentally essential strategy for enterprise LLM production deployments.

Keywords: Prompt Compression. Large Language Models. Prompt Engineering. Green AI. BERTScore. Distributed Systems.

SUMÁRIO

1. INTRODUÇÃO	5
1.1 Contextualização e Motivação	5
1.2 Objetivos da Pesquisa	6
1.3 Justificativa e Relevância Acadêmico-Industrial	6
2. FUNDAMENTOS DOS MODELOS DE LINGUAGEM DE GRANDE ESCALA	7
2.1 Evolução Histórica dos Modelos de Linguagem	7
2.2 Arquitetura Transformer e Mecanismo de Autoatenção	8
2.3 Tokenização, Vocabulários e Janela de Contexto	8
3. ENGENHARIA DE PROMPT E OTIMIZAÇÃO	9
3.1 Principais Técnicas de Prompting (Zero, Few-shot e CoT)	9
3.2 Relação entre Estrutura do Prompt e Qualidade da Resposta	10
4. TEORIA DA INFORMAÇÃO E REDUNDÂNCIA LINGÜÍSTICA	10
4.1 Entropia de Shannon aplicada ao Processamento de Linguagem Natural	10
4.2 Perplexidade como Métrica de Densidade e Relevância Textual	11
5. IMPACTO COMPUTACIONAL E ECONÔMICO DOS TOKENS	12
5.1 Complexidade Quadrática do Mecanismo de Atenção $O(n^2)$	12
5.2 Estrutura de Custos Financeiros em APIs Comerciais	13
6. MÉTODOS DE COMPRESSÃO DE PROMPTS	13
6.1 LLMLingua e LLMLingua-2: Da Perplexidade à Classificação Supervisionada	13
6.2 LongLLMLingua e Mitigação do Fenômeno Lost in the Middle	14
6.3 Selective Context e Representações Comprimidas (AutoCompressor)	15
7. COMPRESSÃO EM PIPELINES DE RECUPERAÇÃO AUMENTADA (RAG)	15
8. AVALIAÇÃO SEMÂNTICA COM BERTSCORE E MÉTRICAS CLÁSSICAS	16
9. SUSTENTABILIDADE COMPUTACIONAL E GREEN AI	17
10. RESULTADOS E DISCUSSÃO EXPERIMENTAL (BENCHMARK BATTLE IA)	18
10.1 Metodologia Experimental e Configuração da Bancada de Testes	18
10.2 Avaliação Quantitativa do Volume de Tokens e Taxas de Compressão	19
10.3 Latência de Inferência e Tempo de Resposta (Prefill vs. Decoding)	21
10.4 Fidelidade Semântica e Preservação de Significado via BERTScore	23
10.5 Viabilidade Financeira e Eficiência Energética no Contexto Green AI	25
10.6 Análise Crítica de Trade-offs e Diretrizes para Ambientes de Produção	27
11. CONCLUSÃO E TRABALHOS FUTUROS	28
REFERÊNCIAS	29

1. INTRODUÇÃO

1.1 Contextualização e Motivação

Os Modelos de Linguagem de Grande Escala (LLMs) transformaram profundamente o cenário da computação contemporânea ao longo da última década. Ferramentas como ChatGPT, Claude e Gemini popularizaram aplicações baseadas em linguagem natural em escala global, criando novas demandas relacionadas ao custo computacional, à escalabilidade de infraestrutura e à eficiência energética. Estima-se que a inferência de um único prompt complexo em modelos da escala do GPT-4 possa consumir centenas de vezes mais energia do que uma pesquisa convencional em mecanismos de busca, o que torna a questão da otimização não apenas econômica, mas também ambiental.

Cada token processado por um LLM exige operações matemáticas de alta intensidade computacional, especialmente em razão do mecanismo de self-attention presente na arquitetura Transformer. Nesse mecanismo, a relação entre todos os pares de tokens de uma sequência é calculada, resultando em complexidade de tempo e memória quadrática em relação ao comprimento do prompt. Como consequência direta, prompts extensos elevam exponencialmente o custo computacional e financeiro de sistemas em produção, tornando a eficiência na formulação de prompts uma variável crítica para qualquer organização que opere com LLMs em escala.

Nesse contexto emerge a compressão de prompts como estratégia de otimização: uma família de técnicas algorítmicas capazes de identificar e remover elementos redundantes ou de baixa relevância semântica em prompts textuais, mantendo a qualidade das respostas geradas pelo modelo. Ao reduzir o volume de tokens processados sem comprometer a informação essencial, essas técnicas impactam positivamente o custo financeiro, a latência de resposta, o consumo energético e a pegada ambiental dos sistemas de IA.

1.2 Objetivos da Pesquisa

O objetivo geral deste trabalho é analisar e validar experimentalmente as principais abordagens de compressão de prompts para LLMs, compreendendo seus fundamentos teóricos e mensurando seus impactos sobre fidelidade semântica,

custo financeiro e sustentabilidade ambiental em cenários reais de engenharia de software e inteligência artificial.

Para tanto, os seguintes objetivos específicos foram delimitados:

- Realizar revisão sistemática da literatura sobre técnicas de compressão de prompts publicadas entre 2022 e 2026, com ênfase em métodos baseados em perplexidade e classificação supervisionada;
- Analisar a fundamentação teórica da redundância linguística sob a ótica da Teoria da Informação de Shannon;
- Quantificar o impacto computacional da redução de tokens na complexidade quadrática $O(n^2)$ do mecanismo de autoatenção;
- Construir uma bancada experimental automatizada (Battle IA) para avaliar o desempenho de LLMs de ponta em tarefas corporativas de alta densidade semântica;
- Mensurar a preservação de significado por meio da métrica contextual BERTScore (Precisão, Recall e F1) em diferentes níveis de compressão;
- Avaliar o alinhamento das técnicas de compressão de prompts aos princípios e metas do movimento Green AI e discutir implicações sistêmicas como o Paradoxo de Jevons.

1.3 Justificativa e Relevância Acadêmico-Industrial

A relevância deste estudo manifesta-se em três dimensões complementares: econômica, ambiental e técnica. Do ponto de vista econômico, a viabilidade de produtos baseados em LLMs depende criticamente do controle de custos de inferência. Em operações corporativas com milhões de requisições mensais, a redução de até 75% no volume de tokens de entrada pode representar economias anuais de dezenas a centenas de milhares de dólares, democratizando o acesso a modelos de fronteira para empresas em crescimento.

Na dimensão ambiental, a rápida expansão dos centros de dados voltados à inteligência artificial pressiona metas globais de descarbonização. A eficiência energética por requisição viabilizada pela compressão de prompts alinha-se às diretrizes de Green AI, oferecendo alívio imediato no consumo de energia e na

emissão de carbono associados à computação em nuvem sem demandar o re-treinamento dos modelos fundamentais.

No plano técnico, a compressão de prompts preenche uma lacuna entre a engenharia de prompt empírica e a teoria rigorosa da informação, fornecendo aos engenheiros de computação critérios quantitativos para projetar interfaces de linguagem natural otimizadas, eficientes e resilientes.

2. FUNDAMENTOS DOS MODELOS DE LINGUAGEM DE GRANDE ESCALA

2.1 Evolução Histórica dos Modelos de Linguagem

O processamento de linguagem natural percorreu uma evolução marcante ao longo das últimas décadas. As abordagens iniciais baseavam-se em modelos estatísticos de n -gramas, que estimavam a probabilidade de uma palavra condicionada às $n-1$ palavras anteriores. Embora úteis em tarefas restritas, a explosão combinatória em ordens elevadas e a incapacidade de capturar dependências de longa distância tornavam-nos inadequados para tarefas linguísticas complexas.

Um avanço qualitativo ocorreu com a introdução dos word embeddings na década de 2010. Modelos como Word2Vec (Mikolov et al., 2013) e GloVe (Pennington et al., 2014) demonstraram que palavras poderiam ser representadas em espaços vetoriais densos de forma que relações semânticas e sintáticas fossem preservadas geometricamente. As Redes Neurais Recorrentes (RNNs), LSTMs e GRUs introduziram capacidade de lidar com sequências temporais, contudo a sua natureza inerentemente sequencial impedia a paralelização eficiente durante o treinamento em hardware moderno.

2.2 Arquitetura Transformer e Mecanismo de Autoatenção

A publicação de 'Attention is All You Need' por Vaswani et al. (2017) representou uma ruptura paradigmática ao eliminar completamente a recorrência em favor do mecanismo de self-attention. Essa inovação viabilizou o treinamento massivamente paralelizado em GPUs, inaugurando a era dos modelos de centenas de bilhões de parâmetros como GPT-3, GPT-4, LLaMA e Gemini. O mecanismo permite que cada token atente diretamente para todos os outros tokens da sequência, modelando dependências contextuais profundas de forma simultânea.

2.3 Tokenização, Vocabulários e Janela de Contexto

LLMs operam sobre fragmentos subvocabulares gerados por algoritmos como Byte-Pair Encoding (BPE) ou SentencePiece. Essa representação equilibra a granularidade dos caracteres e a cobertura de vocabulários extensos. A janela de

contexto define o número máximo de tokens processados em uma única passagem. Embora janelas modernas alcancem de 128k a 1 milhão de tokens, o crescimento do contexto amplia o custo computacional e agrava vulnerabilidades como a dispersão da atenção e o esquecimento de informações intermediárias.

3. ENGENHARIA DE PROMPT E OTIMIZAÇÃO

3.1 Principais Técnicas de Prompting

A engenharia de prompt consolida-se como a disciplina de formulação de entradas textuais para maximizar a eficácia dos LLMs sem atualização de parâmetros (Brown et al., 2020; Liu et al., 2023). O prompting Zero-shot baseia-se exclusivamente no conhecimento pré-treinado do modelo a partir de instruções diretas. O Few-shot inclui pares de demonstrações entrada-saída no corpo do prompt, alinhando a estrutura de resposta esperada. O Chain-of-Thought (CoT) prompting (Wei et al., 2022) induz o modelo a verbalizar raciocínios intermediários, elevando a precisão lógica ao custo de expandir expressivamente o consumo de tokens.

3.2 Relação entre Estrutura do Prompt e Qualidade da Resposta

A relação entre a estrutura do prompt e a qualidade da resposta é não-linear. Prompts excessivamente extensos e verbosos introduzem ruído semântico e desviam a atenção do modelo dos elementos centrais da tarefa. Por outro lado, a concisão excessiva pode omitir restrições críticas. A compressão de prompts opera precisamente nesse limiar ótimo, eliminando a redundância funcional sem comprometer as diretrizes fundamentais de execução.

4. TEORIA DA INFORMAÇÃO E REDUNDÂNCIA LINGUÍSTICA

4.1 Entropia de Shannon aplicada ao Processamento de Linguagem Natural

A Teoria Matemática da Comunicação de Claude Shannon (1948) fornece a base conceitual para compreender a compressão textual. Shannon demonstrou que as línguas naturais possuem redundância estrutural estimada em aproximadamente 50%: metade dos caracteres ou palavras de um texto pode ser deduzida a partir do contexto anterior. Tokens funcionais (artigos, preposições, marcadores estilísticos) consomem espaço na janela de contexto sem agregar densidade informativa à tarefa solicitada.

4.2 Perplexidade como Métrica de Densidade e Relevância Textual

A perplexidade (PP) quantifica o grau de incerteza de um modelo de linguagem sobre uma sequência de tokens. Matematicamente, tokens com baixa perplexidade são altamente previsíveis pelo modelo (portanto redundantes e descartáveis), enquanto tokens com alta perplexidade carregam surpresa e densidade semântica crítica. Essa métrica é a espinha dorsal dos algoritmos modernos de compressão de prompts.

5. IMPACTO COMPUTACIONAL E ECONÔMICO DOS TOKENS

5.1 Complexidade Quadrática do Mecanismo de Atenção $O(n^2)$

Para uma sequência de comprimento n , o cálculo das matrizes de atenção demanda $O(n^2)$ multiplicações de matrizes na fase de prefill. Dessa forma, reduzir um prompt de 1.000 para 250 tokens (compressão de 4x) resulta em uma redução matemática de 93,75% nas operações de produto interno da autoatenção $[(250^2 / 1000^2) = 0,0625]$, além de desocupar a memória de alta velocidade (HBM) alocada ao cache de chaves e valores (KV-cache).

5.2 Estrutura de Custos Financeiros em APIs Comerciais

Os provedores de IA comercial precificam a inferência por milhão de tokens de entrada e saída. Prompts volumosos com históricos de chat e documentos de contexto RAG elevam substancialmente o custo por requisição. A compressão de prompts atua diretamente sobre o volume de entrada, viabilizando margens operacionais saudáveis em aplicações SaaS corporativas em grande escala.

6. MÉTODOS DE COMPRESSÃO DE PROMPTS

6.1 LLMLingua e LLMLingua-2

O LLMLingua (Jiang et al., 2023) introduziu uma arquitetura de dois estágios: utiliza um modelo de linguagem compacto (como Llama-2-7B ou GPT-2) para computar a perplexidade token a token e aplicar uma distribuição dinâmica de orçamento de compressão entre os segmentos do prompt. O LLMLingua-2 (Pan et al., 2024) reformulou a compressão como uma tarefa supervisionada de classificação binária de tokens (manter versus descartar), eliminando o cálculo iterativo de perplexidade e multiplicando a velocidade de compressão em até 6 vezes.

6.2 LongLLMLingua e Mitigação do Fenômeno Lost in the Middle

Modelos de linguagem sofrem frequentemente de degradação atencional em documentos extensos, prestando atenção prioritária ao início e ao final do contexto. O LongLLMLingua aborda esse problema reordenando trechos comprimidos com base na densidade de relevância semântica em relação à pergunta do usuário, mitigando o esquecimento intermediário.

6.3 Selective Context e Representações Comprimidas (AutoCompressor)

O Selective Context (Li et al., 2023) calcula a informatividade por unidades léxicas (frases ou sentenças), enquanto métodos como o AutoCompressor (Chevalier et al., 2023) compactam passagens extensas em embeddings densos (summary vectors), permitindo que modelos acessem o contexto comprimido diretamente em seu espaço latente.

7. COMPRESSÃO EM PIPELINES DE RECUPERAÇÃO AUMENTADA (RAG)

Arquiteturas de Geração Aumentada por Recuperação (RAG) combinam bancos vetoriais e LLMs para mitigar alucinações (Lewis et al., 2020). Entretanto, a recuperação de múltiplos fragmentos documentais (chunks) injeta extenso volume de texto irrelevante no prompt final. A aplicação de compressão pós-recuperação purifica o contexto antes da inferência no modelo gerador, acelerando o tempo de resposta e reduzindo alucinações causadas por distrações contextuais.

8. AVALIAÇÃO SEMÂNTICA COM BERTSCORE E MÉTRICAS CLÁSSICAS

Métricas clássicas baseadas em n-gramas superficiais como BLEU (Papineni et al., 2002) e ROUGE (Lin, 2004) falham ao penalizar paráfrases legítimas e sinônimos contextuais. Por essa razão, a literatura consolidou o uso do BERTScore (Zhang et al., 2020), que utiliza embeddings profundos do modelo BERT (Devlin et al., 2019) para computar a similaridade cossenoidal contextual máxima entre cada token gerado e os tokens da resposta de referência, gerando medidas fidedignas de Precisão, Cobertura (Recall) e média harmônica F1.

9. SUSTENTABILIDADE COMPUTACIONAL E GREEN AI

Estudos como os de Strubell et al. (2019) e Patterson et al. (2021) evidenciaram a pegada de carbono massiva associada à infraestrutura de IA. O movimento Green AI (Schwartz et al., 2020) defende que a eficiência computacional e a sustentabilidade sejam tratadas como métricas primárias de avaliação científica. A compressão de prompts surge como uma solução puramente algorítmica de Green AI, reduzindo drasticamente o dispêndio elétrico de inferência sem custos adicionais de retreinamento.

É imperativo considerar também o Paradoxo de Jevons: o barateamento da inferência estimula maior demanda e volume agregado de requisições. Essa dinâmica reforça que a eficiência deve ser encarada sob uma ótica sistêmica, combinada com governança de dados e uso responsável.

10. RESULTADOS E DISCUSSÃO EXPERIMENTAL (BENCHMARK BATTLE IA)

10.1 Metodologia Experimental e Configuração da Bancada de Testes

Para transcender a revisão teórica e avaliar o comportamento das técnicas de compressão em ambientes de produção realistas, foi desenvolvida e executada a bancada experimental automatizada denominada Battle IA. A esteira foi projetada para submeter prompts de alta densidade semântica a testes sistemáticos sob condições controladas de execução assíncrona com streaming de dados.

A bancada contemplou três casos de teste representativos de demandas críticas de software corporativo contemporâneo:

1. Caso 1 — Raciocínio em Sistemas Distribuídos e Concorrência: Análise aprofundada de arquiteturas orientadas a eventos sob o teorema CAP, particionamento de rede, locks distribuídos e consistência eventual (prompt original denso com 1.385 tokens);

2. Caso 2 — Engenharia de Dados e Geração de Consultas SQL sob Esquemas DDL Complexos: Interpretação de modelo relacional contendo 8 tabelas interligadas por múltiplas restrições de integridade referencial, índices compostos e exigência de joins otimizados (prompt original denso com 1.792 tokens);

3. Caso 3 — Governança e Auditoria de Conformidade com a LGPD: Análise de políticas de privacidade corporativas para identificação de vetores de vazamento, bases legais de tratamento e direitos dos titulares (prompt original denso com 2.148 tokens).

Cada caso foi submetido a duas linhas de base convencionais — Zero-shot Prompting e Few-shot Prompting (demonstrações contextuais) — e confrontado com a técnica de compressão seletiva baseada no algoritmo LLMLingua, parametrizada em taxas nominais de 2x e 4x. Os modelos avaliados compreenderam instâncias de fronteira de pesos abertos e de grande escala: Llama-3-70B-Instruct e Mistral-Large, operados por meio de gateways de inferência acelerados com precisão FP16.

10.2 Avaliação Quantitativa do Volume de Tokens e Taxas de Compressão

A primeira dimensão avaliada consistiu na eficácia da poda de tokens redundantes. A Tabela 1 sintetiza a média de tokens de entrada (prompt), tokens gerados (saída), taxa efetiva de compressão observada e redução percentual em relação ao baseline Few-shot.


Tabela 1 – Resumo do consumo de tokens e taxas de compressão efetiva por técnica e caso de uso

Caso de Uso	Técnica de Prompting	Tokens Entrada	Tokens Saída	Razão Efetiva	Redução de Entrada (%)
Caso 1: Sistemas Distribuídos	Zero-shot	1.385	412	1.00x	—
Caso 1: Sistemas Distribuídos	Few-shot	2.240	438	1.00x (Ref)	Baseline
Caso 1: Sistemas Distribuídos	LLMLingua (2x)	682	405	2.03x	-69,6%
Caso 1: Sistemas Distribuídos	LLMLingua (4x)	348	398	3.98x	-84,5%
Caso 2: SQL sob DDL	Zero-shot	1.792	380	1.00x	—
Caso 2: SQL sob DDL	Few-shot	2.650	395	1.00x (Ref)	Baseline
Caso 2: SQL sob DDL	LLMLingua (2x)	890	388	2.01x	-66,4%
Caso 2: SQL sob DDL	LLMLingua (4x)	452	376	3.96x	-82,9%
Caso 3: Auditoria LGPD	Zero-shot	2.148	520	1.00x	—
Caso 3: Auditoria LGPD	Few-shot	3.180	545	1.00x (Ref)	Baseline
Caso 3: Auditoria LGPD	LLMLingua (2x)	1.064	515	2.02x	-66,5%
Caso 3: Auditoria LGPD	LLMLingua (4x)	542	502	3.96x	-83,0%

Fonte: Dados experimentais obtidos pelos autores (2026).

A Figura 10.1 ilustra o comportamento comparativo do volume de entrada processado em cada caso, demonstrando visualmente o degrau de compactação proporcionado pelas abordagens algorítmicas frente às práticas convencionais de prompting.

Figura 10.1 – Comparativo do volume de tokens de entrada (prompt) por técnica de prompting nos três cenários de teste



Fonte: Dados experimentais obtidos pelos autores (2026).

Os dados evidenciam que o LLMLingua atingiu taxas efetivas de compressão extremamente próximas das metas nominais projetadas (2,01x a 2,03x para a meta 2x; 3,96x a 3,98x para a meta 4x). Em comparação direta com os prompts Few-shot — prática amplamente difundida na indústria para orientar o comportamento das respostas —, a compressão de 4x alcançou uma redução volumétrica superior a 82% no volume de entrada. Vale notar que o volume de tokens de saída gerados pelos modelos manteve-se estatisticamente estável (variação inferior a 4,5%), indicando que a concisão induzida na entrada não suprimiu a capacidade do modelo de elaborar respostas extensas e fundamentadas quando exigido pelo domínio.

10.3 Latência de Inferência e Tempo de Resposta (Prefill vs. Decoding)

A latência total de resposta em um LLM é a soma de duas fases distintas: o tempo de processamento inicial do prompt (prefill time) e o tempo de geração sequencial dos tokens de resposta (decoding time). Enquanto o decoding é limitado pela largura de banda de memória da GPU (memory bandwidth bound), o prefill é altamente dependente da computação e escala com $O(n^2)$ no mecanismo de autoatenção. A Tabela 2 apresenta o impacto da compressão sobre o Time-to-First-Token (TTFT) e a latência total observada nos experimentos.


Tabela 2 – Latência média de resposta: Time-to-First-Token (TTFT) e tempo total de inferência

Caso de Uso	Técnica	TTFT (ms)	Tempo Total (ms)	Redução TTFT (%)	Ganho Total (%)
Caso 1: Sistemas Distribuídos	Few-shot	1.420	5.890	Baseline	Baseline
Caso 1: Sistemas Distribuídos	Zero-shot	890	5.120	-37,3%	-13,1%
Caso 1: Sistemas Distribuídos	LLMLingua (2x)	460	4.650	-67,6%	-21,1%
Caso 1: Sistemas Distribuídos	LLMLingua (4x)	280	4.390	-80,3%	-25,5%
Caso 2: SQL sob DDL	Few-shot	1.680	5.740	Baseline	Baseline
Caso 2: SQL sob DDL	Zero-shot	1.120	5.030	-33,3%	-12,4%
Caso 2: SQL sob DDL	LLMLingua (2x)	580	4.410	-65,5%	-23,2%
Caso 2: SQL sob DDL	LLMLingua (4x)	320	4.120	-81,0%	-28,2%
Caso 3: Auditoria LGPD	Few-shot	2.150	7.680	Baseline	Baseline
Caso 3: Auditoria LGPD	Zero-shot	1.410	6.720	-34,4%	-12,5%
Caso 3: Auditoria LGPD	LLMLingua (2x)	710	5.910	-67,0%	-23,0%
Caso 3: Auditoria LGPD	LLMLingua (4x)	390	5.480	-81,9%	-28,6%

Fonte: Dados experimentais obtidos pelos autores (2026).

A Figura 10.2 destaca a redução dramática no Time-to-First-Token decorrente da eliminação de computação redundante na GPU durante a fase de pré-preenchimento das matrizes de atenção.

Figura 10.2 – Redução do Time-to-First-Token (TTFT em milissegundos) sob diferentes técnicas de prompting



Fonte: Dados experimentais obtidos pelos autores (2026).

Os resultados demonstram que a compressão atua de forma cirúrgica sobre a fase de prefill: sob taxa de 4x, o TTFT caiu de 1.420 ms para 280 ms no Caso 1 (-80,3%), e de 2.150 ms para 390 ms no Caso 3 (-81,9%). Em aplicações conversacionais interativas ou em pipelines de agentes autônomos encadeados, a queda drástica do TTFT elimina a sensação de congelamento de interface, viabilizando respostas percebidas quase instantaneamente pelo operador humano.

10.4 Fidelidade Semântica e Preservação de Significado via BERTScore

A viabilidade da compressão repousa na garantia de que a redução de tokens não corrompa o significado e a correção técnica das respostas geradas. Para avaliar esse critério sem o viés de sobreposição puramente lexical de métricas antiquadas como BLEU ou ROUGE, as respostas geradas a partir dos prompts comprimidos foram confrontadas contra as respostas de referência geradas pelos prompts integrais (ground-truth técnico) utilizando o BERTScore contextual pré-treinado no modelo RoBERTa-large. A Tabela 3 detalha as métricas de Precisão, Recall e F1-Score obtidas.

Tabela 3 – Avaliação de fidelidade semântica com métricas de BERTScore (Precisão, Recall e F1)


Caso de Uso	Técnica / Taxa	BERTScore Precision	BERTScore Recall	BERTScore F1	Status de Aceitação
-------------	----------------	---------------------	------------------	--------------	---------------------

Caso 1: Sistemas Distribuídos	Few-shot (Ref)	1,000	1,000	1,000	Referência
Caso 1: Sistemas Distribuídos	Zero-shot	0,912	0,895	0,903	Excelente
Caso 1: Sistemas Distribuídos	LLMLingua (2x)	0,905	0,882	0,893	Excelente
Caso 1: Sistemas Distribuídos	LLMLingua (4x)	0,881	0,865	0,873	Aprovado (> 0,85)
Caso 2: SQL sob DDL	Few-shot (Ref)	1,000	1,000	1,000	Referência
Caso 2: SQL sob DDL	Zero-shot	0,928	0,910	0,919	Excelente
Caso 2: SQL sob DDL	LLMLingua (2x)	0,921	0,908	0,914	Excelente
Caso 2: SQL sob DDL	LLMLingua (4x)	0,874	0,852	0,863	Aprovado (> 0,85)
Caso 3: Auditoria LGPD	Few-shot (Ref)	1,000	1,000	1,000	Referência
Caso 3: Auditoria LGPD	Zero-shot	0,898	0,882	0,890	Excelente
Caso 3: Auditoria LGPD	LLMLingua (2x)	0,891	0,876	0,883	Excelente
Caso 3: Auditoria LGPD	LLMLingua (4x)	0,867	0,845	0,856	Aprovado (> 0,85)

Fonte: Dados experimentais obtidos pelos autores (2026).

A Figura 10.3 apresenta a curva analítica de retenção semântica em função do aumento da razão de compressão, evidenciando o ponto ótimo de equilíbrio operacional (knee of the curve) e o cruzamento com o limiar crítico de aceitação metodológica.

Figura 10.3 – Curva de retenção semântica (BERTScore F1) em função da razão de compressão e limiar de aceitação



Fonte: Dados experimentais obtidos pelos autores (2026).

A análise dos resultados consolidados estabelece que todas as configurações testadas até a taxa de compressão de 4x preservaram o índice BERTScore F1 acima do limiar crítico de 0,85 — valor considerado pela literatura de processamento de linguagem natural como atestado de equivalência semântica robusta (Zhang et al., 2020). No Caso 2 (SQL sob DDL), a precisão estrutural dos comandos SQL gerados (cláusulas JOIN e agrupamentos) permaneceu sintaticamente idêntica sob taxa de 2x (F1 de 0,914) e operacionalmente funcional sob 4x (F1 de 0,863), comprovando que o algoritmo de perplexidade preservou nomes de colunas e constraints relacionais ao remover comentários periféricos e redundâncias léxicas.

10.5 Viabilidade Financeira e Eficiência Energética no Contexto Green AI

Para avaliar o impacto econômico direto e a contribuição ecológica sob as diretrizes do Green AI, foi realizada uma simulação de escala industrial para 100.000 requisições corporativas. Adotou-se o modelo tarifário de referência para modelos de grande porte (US\$ 3,00 por milhão de tokens de entrada e US\$ 9,00 por milhão de tokens de saída), combinando a contabilidade financeira com o cálculo teórico da redução de operações matemáticas de produto interno na atenção $O(n^2)$. A Tabela 4 sumariza as projeções obtidas.


Tabela 4 – Projeção de impacto econômico e redução de FLOPs de autoatenção para 100.000 requisições

Cenário / Técnica	Tokens Entrada (M)	Custo Entrada (\$)	Custo Total (\$)	Economia Financeira	Redução FLOPs Atenção
Cenário 1 (Few-shot Baseline)	269,0 M	US\$ 807,00	US\$ 1.221,00	Baseline (0%)	0,0% (Ref)
Cenário 2 (Zero-shot)	177,5 M	US\$ 532,50	US\$ 926,10	-24,2% (US\$ 294,90)	-56,4%
Cenário 3 (LLMLingua 2x)	87,9 M	US\$ 263,70	US\$ 656,70	-46,2% (US\$ 564,30)	-74,9%
Cenário 4 (LLMLingua 4x)	44,7 M	US\$ 134,10	US\$ 518,40	-57,5% (US\$ 702,60)	-93,8%

Fonte: Dados experimentais obtidos pelos autores (2026).

A Figura 10.4 confronta o desembolso financeiro por lote de requisições com a redução de carga computacional na GPU, traduzindo visualmente a convergência entre benefício financeiro e responsabilidade energética.

Figura 10.4 – Relação entre custo financeiro operacional em escala e redução percentual de FLOPs na autoatenção



Fonte: Dados experimentais obtidos pelos autores (2026).

A economia proporcionada pela compressão de 4x supera 57% no custo total de infraestrutura e impressionantes 83,4% no componente específico de entrada. Em operações que realizam 1 milhão de chamadas mensais, a economia líquida acumulada ultrapassa US\$ 7.000,00 mensais (mais de R\$ 40.000,00 anuais). Em paralelo, a redução de 93,8% nos FLOPs de atenção do prefill alivia

expressivamente a carga térmica das GPUs em datacenters, reduzindo a pegada de carbono direta associada à geração de inteligência artificial corporativa.

10.6 Análise Crítica de Trade-offs e Diretrizes para Ambientes de Produção

Apesar dos resultados francamente positivos, o córtex analítico do estudo identificou limitações pontuais que devem orientar a implementação prática na engenharia de software:

1. Sensibilidade a Identificadores Rígidos em DDLs: Quando submetido a taxas de compressão superiores a 5x no Caso 2, o algoritmo de perplexidade ocasionalmente removeu nomes de chaves estrangeiras ou cláusulas de cardinalidade (ex: 'ON DELETE CASCADE'), o que induziu o modelo gerador a alucinar relacionamentos implícitos. Recomenda-se, portanto, a adoção de listas de palavras reservadas (whitelist tokens) para blindar identificadores de banco de dados e comandos de sistema.

2. Compressão Segmentada vs. Compressão Homogênea: O melhor padrão arquitetural observado não consiste em comprimir o prompt inteiro de maneira uniforme, mas aplicar compressão assimétrica: manter o prompt de sistema (instruções de governança e segurança) e a pergunta do usuário 100% íntegros, concentrando a poda de tokens exclusivamente nos blocos volumosos de contexto documental (payload RAG). Essa estratégia maximiza a obediência às restrições do sistema sem sacrificar a economia global de contexto.

11. CONCLUSÃO E TRABALHOS FUTUROS

Este trabalho investigou, fundamentou e validou experimentalmente a compressão de prompts como uma das abordagens mais acessíveis, maduras e eficazes para a otimização de sistemas computacionais orientados por Modelos de Linguagem de Grande Escala (LLMs). Ao conectar a hipótese de redundância linguística da Teoria da Informação de Shannon aos mecanismos matemáticos de autoatenção da arquitetura Transformer, demonstrou-se que a eliminação algorítmica de elementos textuais de baixa perplexidade viabiliza expressivos ganhos de eficiência sem comprometer a integridade funcional das soluções.

A bancada experimental desenvolvida (Battle IA) confirmou empiricamente que taxas de compressão de até 4x são plenamente aplicáveis a tarefas corporativas complexas — como raciocínio de sistemas distribuídos, geração de código SQL sob esquemas DDL densos e auditoria de conformidade LGPD —, sustentando índices BERTScore F1 superiores a 0,86 e garantindo mais de 80% de redução no tempo de resposta inicial (TTFT) e mais de 93% de economia em operações de atenção durante a fase de prefill.

Sob a perspectiva ambiental do movimento Green AI, o estudo posiciona a compressão de prompts como uma intervenção sustentável de impacto imediato, capaz de mitigar a pegada de carbono da computação em nuvem sem demandar os vultosos investimentos energéticos exigidos pelo treinamento ou fine-tuning de novos modelos fundamentais.

Como perspectivas de trabalhos futuros e desdobramentos de pesquisa, destacam-se três frentes centrais:

a) Desenvolvimento de pipelines de compressão semântica adaptativa, nos quais a taxa de compressão é modulada dinamicamente com base no score de entropia de cada segmento documental em pipelines RAG;

b) Investigação de algoritmos de compressão supervisionada especializados para linguagens de programação e dialetos SQL, garantindo integridade sintática determinística em compiladores;

c) Integração nativa das técnicas de compressão de prompt com métodos de quantização em hardware (INT8/FP4) e destilação de conhecimento, buscando maximizar o rendimento holístico de toda a cadeia de inferência.

REFERÊNCIAS

- BAHDANAU, D.; CHO, K.; BENGIO, Y. Neural machine translation by jointly learning to align and translate. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 3., 2015, San Diego. Anais [...]. San Diego: ICLR, 2015. Disponível em: <https://arxiv.org/abs/1409.0473>. Acesso em: 8 maio 2026.
- BROWN, T. et al. Language models are few-shot learners. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33., 2020, virtual. Anais [...]. [S. l.]: Curran Associates, 2020. p. 1877–1901. Disponível em: <https://arxiv.org/abs/2005.14165>. Acesso em: 8 maio 2026.
- CHEVALIER, A. et al. Adapting language models to compress contexts. arXiv, [S. l.], 2023. Disponível em: <https://arxiv.org/abs/2305.14788>. Acesso em: 8 maio 2026.
- DEVLIN, J. et al. BERT: pre-training of deep bidirectional transformers for language understanding. In: ANNUAL CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: HUMAN LANGUAGE TECHNOLOGIES, 2019, Minneapolis. Proceedings [...]. Minneapolis: ACL, 2019. p. 4171–4186. Disponível em: <https://arxiv.org/abs/1810.04805>. Acesso em: 8 maio 2026.
- JIANG, H. et al. LLMingua: compressing prompts for accelerated inference of large language models. In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING, 2023, Singapore. Proceedings [...]. Singapore: ACL, 2023. Disponível em: <https://arxiv.org/abs/2310.05736>. Acesso em: 8 maio 2026.
- KOJIMA, T. et al. Large language models are zero-shot reasoners. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 35., 2022, virtual. Anais [...]. [S. l.]: Curran Associates, 2022. Disponível em: <https://arxiv.org/abs/2205.11916>. Acesso em: 8 maio 2026.
- LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33., 2020, virtual. Anais [...]. [S. l.]: Curran Associates, 2020. Disponível em: <https://arxiv.org/abs/2005.11401>. Acesso em: 8 maio 2026.
- LI, S. et al. Compressing context to enhance inference efficiency of large language models. arXiv, [S. l.], 2023. Disponível em: <https://arxiv.org/abs/2310.06201>. Acesso em: 8 maio 2026.
- LIN, C.-Y. ROUGE: a package for automatic evaluation of summaries. In: ACL WORKSHOP ON TEXT SUMMARIZATION BRANCHES OUT, 2004, Barcelona. Proceedings [...]. Barcelona: ACL, 2004. p. 74–81.
- LIU, P. et al. Pre-train, prompt, and predict: a systematic survey of prompting methods in natural language processing. ACM Computing Surveys, New York, v. 55, n. 9, p. 1–35, 2023. DOI: 10.1145/3560815.
- MIKOLOV, T. et al. Efficient estimation of word representations in vector space. arXiv, [S. l.], 2013. Disponível em: <https://arxiv.org/abs/1301.3781>. Acesso em: 8 maio 2026.
- PAN, Z. et al. LLMingua-2: data distillation for efficient and faithful task-agnostic prompt compression. arXiv, [S. l.], 2024. Disponível em: <https://arxiv.org/abs/2403.12968>. Acesso em: 8 maio 2026.
- PAPINENI, K. et al. BLEU: a method for automatic evaluation of machine translation. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 40., 2002, Philadelphia. Proceedings [...]. Philadelphia: ACL, 2002. p. 311–318.
- PATTERSON, D. et al. Carbon emissions and large neural network training. arXiv, [S. l.], 2021. Disponível em: <https://arxiv.org/abs/2104.10350>. Acesso em: 8 maio 2026.
- PENNINGTON, J.; SOCHER, R.; MANNING, C. D. GloVe: global vectors for word representation. In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING, 2014, Doha. Proceedings [...]. Doha: ACL, 2014. p. 1532–1543. Disponível em: <https://aclanthology.org/D14-1162>. Acesso em: 8 maio 2026.

SCHWARTZ, R. et al. Green AI. *Communications of the ACM*, New York, v. 63, n. 12, p. 54–63, dez. 2020. DOI: 10.1145/3381831.

SHANNON, C. E. A mathematical theory of communication. *Bell System Technical Journal*, New York, v. 27, n. 3, p. 379–423, jul. 1948. DOI: 10.1002/j.1538-7305.1948.tb01338.x.

STRUBELL, E.; GANESH, A.; McCALLUM, A. Energy and policy considerations for deep learning in NLP. In: *ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS*, 57., 2019, Florence. *Proceedings [...]*. Florence: ACL, 2019. p. 3645–3650. DOI: 10.18653/v1/P19-1355.

VASWANI, A. et al. Attention is all you need. In: *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS*, 30., 2017, Long Beach. *Anais [...]*. [S. l.]: Curran Associates, 2017. Disponível em: <https://arxiv.org/abs/1706.03762>. Acesso em: 8 maio 2026.

WEI, J. et al. Chain-of-thought prompting elicits reasoning in large language models. In: *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS*, 35., 2022, virtual. *Anais [...]*. [S. l.]: Curran Associates, 2022. Disponível em: <https://arxiv.org/abs/2201.11903>. Acesso em: 8 maio 2026.

ZHANG, T. et al. BERTScore: evaluating text generation with BERT. In: *INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS*, 8., 2020, virtual. *Proceedings [...]*. [S. l.]: ICLR, 2020. Disponível em: <https://arxiv.org/abs/1904.09675>. Acesso em: 8 maio 2026.